Lab03

Max Stróżyk

Winter 2024/2025

Spis treści

1 Zadanie 1 **2**
- 1.1 Charakterystyka metody Householdera . . . 2
- 1.2 Wyniki i wnioski . . . 2

2 Zadanie 2 **3**
- 2.1 Charakterystyka dekompozycji QR . . . 3
- 2.2 Wyniki i wnioski: . . . 3

3 Zadanie 3 **4**
- 3.1 II norma macierzowa - charakterystyka i porównanie . . . 4
- 3.2 Wyniki i wnioski: . . . 4

4 Zadanie 4 **6**
- 4.1 Metody iteracyjne: charakterystyka i porównanie . . . 6
- 4.2 Wyniki i wnioski: . . . 6
  - 4.2.1 parametr k . . . 6
  - 4.2.2 Parametr c . . . 7
- 4.3 Propozycje . . . 7

1 Zadanie 1

1.1 Charakterystyka metody Householdera

Metoda Householdera to technika stosowana do ortogonalizacji wektorów i redukcji macierzy do prostszej postaci, takiej jak macierz trójkątna górna lub macierz Hessenberga. Jest szeroko wykorzystywana w algorytmach numerycznych, takich jak dekompozycja QR czy obliczanie wartości własnych.

Główna idea metody polega na zastosowaniu transformacji Householdera, która za pomocą macierzy odbicia (Householdera) przekształca dany wektor w prostszą postać.

$$P = I - 2\frac{vv^T}{v^Tv}, \quad Q = I - 2\frac{uu^T}{u^Tu}$$

1.2 Wyniki i wnioski

Tabela przedstawia wyniki testów metody Householdera w odniesieniu do różnych rozmiarów macierzy n oraz relacji pomiędzy wektorami e i x. Wartości błędów są obliczone w następujący sposób:

- **Błąd 1:** Sprawdza błąd macierzy unitarnej P, czyli sprawdza: $P^TP = I$.
- **Błąd 2:** Sprawdza bład macierzy unitarnej Q, tj. $Q^TQ = I$.
- **Błąd 3:** Porównuje wynik Px z $-ke$, gdzie k jest wyrażeniem definiującym skalowanie.
- **Błąd 4:** Sprawdza, czy Qx równa się $-ke$.

Wartości w tabeli reprezentują maksymalne odchylenia od idealnych wyników i wskazują na precyzję algorytmu:

n	k	Błąd 1	Błąd 2	Błąd 3	Błąd 4
3	1.0891	$2.2203e-16$	$2.2205e-16$	$2.2204e-16$	$2.2204e-16$
3000	0.9830	$1.7765e-15$	$1.9983e-15$	$3.2197e-15$	$2.9975e-15$
3000; $e \sim x$	1.000	$1.9983e-15$	$1.8875e-15$	$2.6646e-15$	$3.8857e-15$
3000; e, x - ortogonalne	0.9938	$1.9985e-15$	$1.7763e-15$	$4.2187e-15$	$3.5528e-15$

Wnioski:

- **Precyzja dla małych n:** Dla małych wartości n, np. $n = 3$, metoda Householdera wykazuje bardzo wysoką dokładność z błędami rzędu 10^{-16}. Oznacza to niemal idealną unitarność macierzy P i Q, a także doskonałe odwzorowanie wektora wynikowego.
- **Stabilność dla dużych n:** Dla dużych macierzy ($n = 3000$) metoda nadal zachowuje stabilność numeryczną, choć błędy nieznacznie rosną.
- **Wpływ relacji e i x:** Gdy e jest bliski x, błędy są niezauważalne.
- **Ortogonalność e i x:** W przypadku wektorów ortogonalnych błędy są niezauważalne.

2 Zadanie 2

2.1 Charakterystyka dekompozycji QR

Dekompozycja QR to metoda, która pozwala rozłożyć macierz A na iloczyn dwóch macierzy:

$$A = QR,$$

gdzie Q jest macierzą ortogonalną ($Q^TQ = I$), a R to macierz górna trójkątna. Metoda ta znajduje szerokie zastosowanie w obliczeniach numerycznych, szczególnie w kontekście znajdowania wartości własnych macierzy. Podczas gdy metoda potęgowa iteracyjnie mnoży macierz A przez wektor i normalizuje wyniki, algorytm QR operuje na pełnej bazie wektorów. Dzięki dekompozycji QR kolejne iteracje prowadzą do ortogonalizacji bazy i normalizacji wektorów.

2.2 Wyniki i wnioski:

Wyniki obliczeń błędów numerycznych dla dekompozycji QR przedstawiają się następująco:

Opis błędów:

- **Błąd 1:** Sprawdza unitarność macierzy Q, czyli weryfikuje, czy $Q^TQ = I$. Dla idealnej dekompozycji QR, macierz Q powinna być macierzą ortogonalną.
- **Błąd 2:** Sprawdza, czy iloczyn Q i R daje oryginalną macierz A, czyli czy $QR = A$. Jest to weryfikacja poprawności samej dekompozycji QR.
- **Błąd 3:** Sprawdza unitarność macierzy $Q1$, która powstaje w wyniku dalszych transformacji macierzy Q. Dla macierzy ortogonalnych $Q1$ również powinna być macierzą ortogonalną.
- **Błąd 4:** Sprawdza, czy iloczyn $Q1$ i $R1$ daje oryginalną macierz A. Podobnie jak w przypadku błędu 2, jest to weryfikacja poprawności dekompozycji przy uwzględnieniu dodatkowych transformacji.

Tabela przedstawia wartości błędów numerycznych dla różnych rozmiarów macierzy:

n	błąd-1	błąd-2	błąd-3	błąd-4
3	$8.8817e-16$	$5.5512e-17$	$4.4408e-16$	$3.3308e-16$
500	$5.4369e-13$	$3.5417e-14$	$1.1103e-15$	$7.9382e-15$
100	$3.9967e-15$	$5.6844e-14$	$1.7765e-15$	$3.1265e-13$

Wnioski:

- Dla małych macierzy ($n = 3$), błędy numeryczne są bardzo małe, co wskazuje na wysoką precyzję metody QR w przypadku niewielkich rozmiarów macierzy.
- Wraz ze wzrostem rozmiaru macierzy ($n = 500$), błędy zaczynają rosnąć, co może być efektem akumulacji błędów zaokrągleń i ograniczeń precyzji obliczeń numerycznych, które stają się bardziej widoczne w przypadku dużych macierzy. Błędy są nadal małe ale znacząco większe.
- Dla macierzy symetrycznych, które zostały rozważone w ostatnim wierszu tabeli, błędy zmniejszają się, co świadczy o lepszej stabilności numerycznej metody QR w przypadku tego typu macierzy.
- Ogólnie rzecz biorąc, metoda QR charakteryzuje się dobrą stabilnością numeryczną, szczególnie w kontekście macierzy symetrycznych, gdzie zbieżność jest wyraźniejsza, a błędy są mniejsze.

3 Zadanie 3

3.1 II norma macierzowa - charakterystyka i porównanie

Druga norma macierzowa (norma spektralna) jest zdefiniowana jako największa wartość singularna macierzy A. Oznacza to, że odpowiada pierwiastkowi największej wartości własnej macierzy $A^T A$, co pozwala efektywnie ocenić rozkład wartości w macierzy.

W naszym algorytmie obliczenia tej normy opierają się na wyznaczaniu miejsc zerowych wielomianu charakterystycznego macierzy. Jednak takie podejście jest wrażliwe na błędy numeryczne, szczególnie w przypadku macierzy o bliskich sobie wartościach własnych. Operacje na pierwiastkach wielomianu mogą prowadzić do niepożądanych efektów, takich jak pojawianie się zespolonych wartości błędów wynikających z zaokrągleń lub niestabilności obliczeń.

Standardowo do wyznaczania II normy macierzowej można wykorzystać *metodę potęgową*. Jest to iteracyjna technika, która pozwala na stabilne przybliżenie największej wartości własnej macierzy. W tej metodzie:

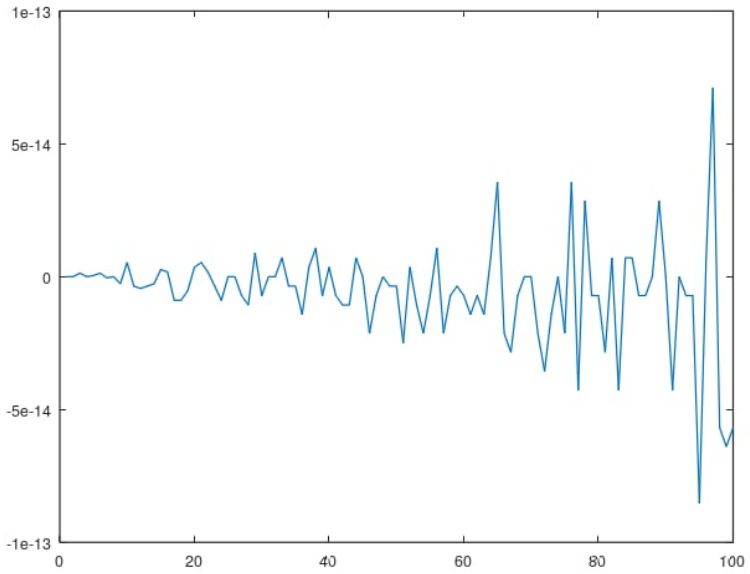
1. Rozpoczynamy od wektora v_0 o dowolnych wartościach.
2. W każdej iteracji obliczamy $v_{k+1} = Av_k$ i normalizujemy wynikowy wektor.
3. Proces powtarzamy, aż kolejne iteracje przyniosą zbieżność do wartości własnej odpowiadającej największej wartości absolutnej.

Metoda ta jest bardziej stabilna niż operacje na wielomianie charakterystycznym, ponieważ unika problemów związanych z błędami zaokrągleń oraz nie wymaga wyznaczania pierwiastków.

3.2 Wyniki i wnioski:

Porównując naszą funkcję norm2 z wbudowaną w Octave funkcją norm, obserwujemy rozbieżności wynikające z błędów numerycznych. Nasza implementacja wykazuje większe wrażliwości na błędy związane z obliczaniem pierwiastków wielomianu charakterystycznego, szczególnie w przypadku macierzy o zbliżonych wartościach własnych. Ponadto, dla macierzy o dużych wartościach na przekątnej mogą występować błędy wynikające z zaokrągleń spowodowanych ograniczoną precyzją operacji arytmetycznych.

Dla lepszego zilustrowania błędów w naszej implementacji mamy rozpisany wykres.



Wnioski:

- Widzimy że otrzymujemy bardzo duże wachania związane z błędem. Algorytm jest niestabilny numerycznie.

4 Zadanie 4

4.1 Metody iteracyjne: charakterystyka i porównanie

W tej sekcji analizujemy trzy popularne metody iteracyjne rozwiązywania układów równań liniowych: metodę Jacobiego, Gaussa-Seidela oraz SOR (Successive Over-Relaxation). Wszystkie te metody oparte są na przekształceniu macierzy układu A w odpowiednią formę, która umożliwia iteracyjne obliczanie przybliżeń rozwiązania.

- **Metoda Jacobiego**: W tej metodzie macierz A dzielimy na sumę $A = D + R$, gdzie D to macierz diagonalna, a R to pozostałe elementy (off-diagonal). Iteracyjny wzór ma postać:

  $$x^{(k+1)} = D^{-1}(b - Rx^{(k)}).$$

  Metoda ta bazuje wyłącznie na wartościach $x^{(k)}$ z poprzedniej iteracji.

- **Metoda Gaussa-Seidela**: Rozkładamy macierz jako $A = L + U$, gdzie L to dolna macierz trójkątna zawierająca również przekątną, a U to macierz górna. Iteracyjny wzór ma postać:

  $$x^{(k+1)} = L^{-1}(b - Ux^{(k+1)}).$$

  Nowe wartości $x^{(k+1)}$ są natychmiast wykorzystywane w bieżących obliczeniach, co przyspiesza zbieżność.

- **Metoda SOR**: To uogólnienie metody Gaussa-Seidela, które wprowadza współczynnik relaksacji ω. Wzór iteracyjny ma postać:

  $$x^{(k+1)} = (1 - \omega)x^{(k)} + \omega L^{-1}(b - Ux^{(k+1)}).$$

  Odpowiedni dobór ω ma kluczowe znaczenie dla efektywności metody.

4.2 Wyniki i wnioski:

Przy wszystkich wyliczeniach ustalamy $x = 0, b = rand(n, 1) * 10$, robimy 1000 prób i bierzemy z nich średnią.

4.2.1 parametr k

Szacujemy k, czyli liczbę iteracji potrzebnych do stwierdzenia zbieżności macierzy. Aby uniknąć błędów związanych z brakiem dominacji diagonalnej, ustalamy $c = n \cdot 10$. Dzięki temu zapewniamy dominującą przekątną w macierzy, co eliminuje błędy wynikające z jej struktury. W takiej sytuacji możemy ustalić $n = 10$, ponieważ przy tej wielkości przekątnej macierzy nie będą pojawiały się problemy związane z jej rozmiarem i brakiem zbieżności.

Metoda	1	3	5	10	16
Jacobi	$4.0556e-03$	$6.5079e-06$	$9.9949e-09$	$2.7341e-15$	$1.1819e-17$
Gauss-Siedel	$3.3702e-03$	$4.4534e-07$	$4.7716e-12$	$2.6600e-17$	$1.8228e-17$
SOR	0.010987	$1.3029e-04$	$1.2422e-06$	$2.5774e-11$	$2.3522e-17$

Wnioski:

- Metoda SOR – wpływ źle dobranego współczynnika relaksacji:
  Metoda SOR, choć teoretycznie powinna charakteryzować się najszybszą zbieżnością, w naszych obliczeniach tego nie potwierdza. Wynika to z faktu, że zastosowano stały współczynnik relaksacji, który został nieodpowiednio dobrany. W efekcie metoda SOR wykazuje słabszą efektywność. Można zatem stwierdzić, że przy źle dobranym współczynniku relaksacji skuteczność tej metody znacząco maleje.

- Porównanie metod Jacobiego i Gaussa-Seidla:
  Analiza wyników pokazuje, że metoda Gaussa-Seidla osiąga szybszą zbieżność już od pierwszej iteracji. Wynika to z charakteru algorytmu, w którym nowe wartości obliczane w bieżącej iteracji są natychmiast wykorzystywane w kolejnych obliczeniach. Z kolei metoda Jacobiego bazuje wyłącznie na wartościach z poprzedniej iteracji, co spowalnia proces zbieżności.

4.2.2 Parametr c

Szacujemy c, które jest parametrem odpowiedzialnym za wartość dodaną na diagonali w macierzy $A + c \cdot \text{eye}(n)$. Ustalamy $k = 100$, aby mieć pewność co do zbieżności.

- przypadek dla $c = n/2$

Metoda	3	10	100
Jacobi	$1.4872e-08$	$2.0980e-03$	$8.8618e-03$
Gauss-Siedel	$5.8098e-16$	$3.9518e-16$	$17138e-16$
SOR	$5.9233e-16$	$3.9828e-16$	$17124e-16$

- przypadek dla $c = 10 * n$

Metoda	3	10	100
Jacobi	$3.9344e-17$	$2.5617e-17$	$1.0956e-17$
Gauss-Siedel	$4.0613e-17$	$2.5840e-17$	$1.0976e-17$
SOR	$3.7866e-17$	$2.5573e-17$	$1.0902e-17$

Wnioski:

- Możemy zauważyć że takie przybliżenie c które sugeruje nam średnia $E[\sum_i^n X_i]$, gdzie $X_1 \sim \text{U}([0, 1])$ jest dobrym szacowaniem. Błędy związane z metodą Jacobiego musza wynikac z samego algorytmu, ale nii rozumiem dlaczego pojawiają się dla

4.3 Propozycje

Moment stopu: Ustalamy p i definiujemy moment stopu w momencie n jeśli pradziwe będzie wyrażenie:

$$\left| \frac{x_n - x_{n-1}}{x_n} \right| \times 100 < p$$